

UNIVERSITÀ DI MESSINA

DIPARTIMENTO DI SCIENZE MATEMATICHE E
INFORMATICHE, SCIENZE FISICHE E DELLA TERRA

CORSO DI LAUREA TRIENNALE IN INFORMATICA

Analisi del raffronto tra Neo4j e MongoDB nel caso di studio dell'identificazione di attività criminali

Autori:

Gabriele ALOISIO (503264)
Samuel Giacomo RAFFA
(518206)

Docenti:

prof. Antonio CELESTI
prof. Massimo VILLARI

29 novembre 2022



Indice

1	Abstract	2
2	Introduzione	3
3	Caso di studio	4
4	Architettura	5
4.1	Neo4j	5
4.2	MongoDB	5
4.3	Python	6
5	Implementazione	6
5.1	Generazione dei dati	7
5.2	Importazione dei dati	8
6	Risultati degli esperimenti	9
6.1	2 WHERE 1 JOIN	10
6.2	2 WHERE 2 JOIN	11
6.3	3 WHERE 1 GROUP BY	12
6.4	2 WHERE 2 JOIN 1 GROUP BY	13
7	Conclusioni	14

1 Abstract

2 Introduzione

In questa trattazione scientifica si descrivono le differenze del rendimento di calcolo tra due popolari *Database Management Systems* (DBMS) di tipo NoSQL. I DBMS in questione sono il graph-oriented Neo4j e il document-oriented MongoDB. I DBMS NoSQL concedono di gestire il dato in modo più flessibile, rispetto al tradizionale e rigido modello tabulare dei database relazionali. I NoSQL infatti permettono di modellare la struttura in base alla necessità, introducendo paradigmi strutturali come *grafo*, *column-based* e *key-value*, ognuno aventi i suoi punti forti e casi obiettivo. Con essi comparirono anche il concetto di scalabilità delle basi di dati come sistemi distribuiti, dando vita al *Teorema CAP*, di Eric Brewer. Questo teorema afferma che **per un sistema informatico distribuito è impossibile fornire simultaneamente tutte e tre le seguenti garanzie:**

- Coerenza (copy-consistency)
- Disponibilità (availability)
- Tolleranza di partizione (partitioning)

Di fatto, le uniche coppie formabili con sistemi reali sono CP, AP e CA.

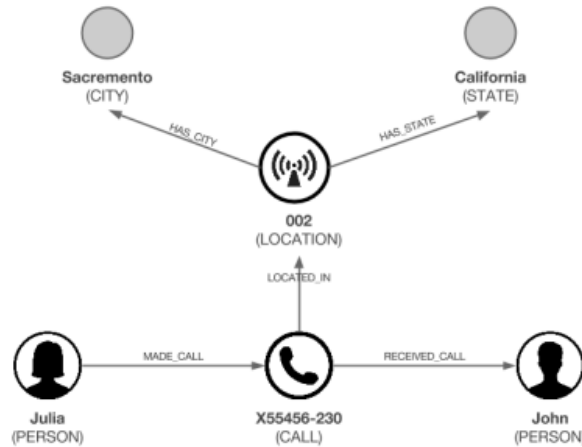
In questo trattato sono illustrate le misurazioni di performance (tempo di esecuzione e di risposta) dei DBMS NoSQL presi in considerazione in riferimento a quattro query scelte con complessità computazionale incrementale. Per questa analisi è stato scelto il caso di studio *How to use graph technology to identify criminal activities in call records?*[1] presentato da Linkurious. I test sono stati eseguiti su una macchina virtuale *Debian Bullseye 11.5.0* con 6GB di memoria RAM e 4 core di un *AMD Ryzen 7 3700X* dedicati. Viene utilizzato il linguaggio *Python* per la generazione del dataset fittizio e il plotting delle misurazioni tramite la libreria `matplotlib`.

3 Caso di studio

Si pone il problema dell'identificazione dell'attività criminale tramite l'analisi delle chiamate telefoniche effettuate nell'arco di tempo e nel luogo più inerenti al caso. Vengono utilizzati i DBMS NoSQL per facilitare il processo di rintracciamento di soggetti o per lo meno il restringimento del campo di ricerca. Questo viene fatto avvantaggiandosi delle rappresentazioni di strutture dati dei DBMS NoSQL rispetto alla tradizionale rappresentazione tabulare dei DBMS classici.

Prendiamo come esempio un gruppo di criminali che compie un furto. Sappiamo che il furto è avvenuto in un luogo L ad un tempo t . Tramite i strumenti a nostra disposizione, possiamo effettuare una ricerca sul database delle chiamate effettuate nel luogo L ed in un intorno definito di t e grazie alla modellazione a grafo è possibile visualizzare le chiamate incrociate, permettendoci di identificare terzi che sono inclusi indirettamente nel crimine.

Supposto che i gestori telefonici diano accesso al database e alla sua architettura, possiamo ammettere una struttura del tipo:



Da qui desumiamo

4 Architettura

4.1 Neo4j

Neo4j è un DBMS NoSQL *graph-oriented* open source sviluppato in Java. Permette un utilizzo in modalità server ed una modalità embedded. Lanciato in modalità server il database è un processo indipendente a cui si accede tramite lo stile architetturale REST. Sono supportati i plugin. In modalità embedded, il processo incorpora il database nell'applicazione Java e viene eseguito all'interno della JVM. Per l'importazione massiva di dati è supportata l'esecuzione in modalità non concorrente. Al dato importato è possibile crearne un nodo ed assegnarvi il tipo di dato (tipi elementari di Java) ed un nome. Come risultato abbiamo un grafo *schema-less*, che Permette un'eterogeneità del dato con il minimo sforzo. Neo4j si mostra molto efficiente nell'estrazione e rappresentazione di strutture ad albero come nei file XML, filesystem e reti. Da questo derivano implementazioni pronte all'uso di operazioni più comuni sui grafi come l'algoritmo di Dijkstra e ricerca dei cicli. Risulta invece scomodo nelle ricerche complesse, per esempio basate su confronti matematici e non supporta lo *sharding*.

4.2 MongoDB

MongoDB è un DBMS NoSQL *document-oriented*. Si basa sulla memorizzazione in base di documenti in formato *BSON*, ispirato al JSON ma con l'aggiunta della dinamicità. Supporta query *ad hoc* per la ricerca su base *regex*, intervalli o campi. Qualsiasi campo è indicizzabile, anche con indici secondari, unici, sparsi, geospaziali e full-text. MongoDB dispone dei *text-replica set*, cioè due o più copie di dati. Ogni copia è identificata come primaria o secondaria. Quando una replica primaria fallisce viene avviato un processo per la determinazione della copia più adatta a sostituire quella primaria. Lo *sharding* permette a MongoDB di scalare orizzontalmente, implementando inoltre un meccanismo di load-balancing. La funzione GridFS permette di utilizzare il DBMS come file system, esponendo agli sviluppatori delle funzioni per la manipolazione del dato. GridFS divide il file in chunks e memorizza ognuno di questi in un documento separato.

4.3 Python

Python è un linguaggio di programmazione orientato agli oggetti. Si è scelto di utilizzare questo linguaggio per la semplicità di utilizzo e la facile disponibilità dei driver per accedere e manipolare i database MongoDB e Neo4j. Dispone inoltre di `matplotlib`, una libreria per la generazione di grafici. Si utilizza oltre ciò la libreria *Faker* per generare i dati fittizi.

5 Implementazione

5.1 Generazione dei dati

Si generano quattro dataset di dimensioni diverse da inserire successivamente sui database MongoDB e Neo4j. Le dimensioni stabilite sono 100%, 75%, 50%, 25%, che indicano rispettivamente le dimensioni dei dataset in base al dataset con il 100% del contenuto di informazioni. Per popolare il database con dati fittizi, si è scritto un codice Python che utilizza Faker. Un file *ini* contiene un valore fisso che indica il numero di record da generare. Al momento dell'avvio dello script viene passato un parametro L che indica la percentuale del carico in base a questi valori. Come valori predefiniti si è scelto 50000 persone, 10000 celle e 200000 chiamate.

5.2 Importazione dei dati

6 Risultati degli esperimenti

6.1 2 WHERE 1 JOIN

6.2 2 WHERE 2 JOIN

6.3 3 WHERE 1 GROUP BY

6.4 2 WHERE 2 JOIN 1 GROUP BY

7 Conclusioni

Riferimenti bibliografici

- [1] <https://linkurious.com/blog/how-to-use-phone-calls-and-network-analysis-to-identify-criminals/>